Interpretación del contraste tumor frente a tejido normal (TCGA-BRCA)

Alejandro Román Ruiz — Tarea 02, Bioinformática y Análisis Genómico

1. Contraste y modelo

Se comparan 75 muestras de mama de TCGA-BRCA: tejido tumoral (Primary_Solid_Tumor) frente a tejido normal adyacente (Solid_Tissue_Normal). El modelo de DESeq2 es `~ site + plate`, de modo que el efecto tumor/normal se estima descontando el efecto técnico de la placa de secuenciación. Tras filtrar genes con al menos 10 lecturas en al menos 20 muestras, se analizan 17606 genes.

2. Sentido de log2FoldChange

El nivel de referencia es el tejido normal, así que log2FoldChange = log2(expresión en tumor / expresión en normal). Un valor positivo indica mayor expresión en tumor y uno negativo, mayor expresión en tejido normal. Al ser una escala logarítmica en base 2, cada unidad equivale a duplicar la expresión: log2FC = 1 significa el doble, y *MMP1* (log2FC = 7,93) se expresa unas 240 veces más en tumor.

3. Criterio estadístico

Para cada gen, DESeq2 aplica un test de Wald sobre el log2FoldChange. Como se hacen 17606 tests a la vez, los p-valores se corrigen por el método de Benjamini-Hochberg, que controla la tasa de falsos descubrimientos (FDR), y se usa el p-valor ajustado (padj). Se combinan dos umbrales:

- **padj < 0,05** (evidencia estadística): 10240 genes;
- además **|log2FC| > 1**, es decir, un cambio de al menos el doble (relevancia biológica): 4054 genes diferencialmente expresados, 2115 sobreexpresados y 1939 infraexpresados en tumor.

El segundo umbral es necesario porque, con 75 muestras, cambios muy pequeños pueden ser estadísticamente significativos sin ser biológicamente relevantes.

4. Genes destacados

Entre los genes sobreexpresados más significativos aparecen dos grupos:

- **Genes de matriz extracelular y remodelación tisular:** *MMP1*, *MMP11*, *COL10A1* y *COL11A1*. *MMP11* se ha asociado a progresión tumoral en cáncer de mama (Kim et al. 2021; Zhuang et al. 2021).
- **Genes de proliferación:** *PKMYT1*, regulador de la entrada en mitosis, y *NUF2*, componente del cinetocoro. El marcador clásico de proliferación *MKI67* también está sobreexpresado (log2FC = 3,39, unas 10 veces más; padj = $1{,}4 \cdot 10^{-23}$).

Entre los infraexpresados destacan *ATP1A2*, *GPAM* (síntesis de lípidos), *RDH5*, *HSD17B13* y *MME* (CD10, marcador de células mioepiteliales). Son genes propios de los componentes no tumorales del tejido mamario.

5. Procesos GO (Biological Process)

En los genes up predominan *chromosome segregation* (padj = $3{,}8 \cdot 10^{-17}$), *chromosome organization*, *DNA repair* y *cell cycle process*. También aparece una firma inmune (*immune response*, *adaptive immune response*, *lymphocyte activation*). En los genes down predominan *lipid metabolic process*, *fat cell differentiation*, *circulatory system development* y *angiogenesis*.

6. Vías Reactome

Reactome confirma la firma proliferativa en los genes up: *Cell Cycle* (padj = $9{,}9 \cdot 10^{-22}$), *Cell Cycle, Mitotic*, *Cell Cycle Checkpoints* y *M Phase*, además de *Immune System*. En los down aparecen *Adipogenesis*, *Metabolism of lipids*, la regulación de dianas de PPARG por los complejos MLL3/MLL4 (otra vez adipogénesis) y *Muscle contraction*.

7. Integración

Los tres niveles de evidencia (gen, proceso y vía) son coherentes. El tejido tumoral combina:

1. una firma proliferativa fuerte (ciclo celular y mitosis), apoyada por *MKI67*, *PKMYT1* y *NUF2*;
2. un componente de remodelación de la matriz y de interacción tumor-estroma (MMPs y colágenos);
3. una señal inmune compatible con infiltración linfocitaria.

A la vez, pierde de forma relativa programas metabólicos (lípidos, adipogénesis) y de diferenciación propios del tejido mamario normal.

8. Limitaciones

- Es RNA-seq bulk: cada muestra mezcla varios tipos celulares. El tejido normal adyacente es rico en adipocitos, por lo que parte de la firma down, y de la inmune up, puede reflejar diferencias de composición celular más que cambios de regulación dentro de las mismas células.
- El enriquecimiento usa como universo los genes DE, no todos los genes analizados, así que compara up y down dentro de los genes que cambian.
- Los padj difieren ligeramente de los del enunciado: mismos genes, mismo orden y mismo log2FC. Lo más probable es que se deba a una versión distinta de DESeq2. Las versiones usadas están en `logs/sessionInfo.txt`.